



# Protocolo de Gestión y Procesamiento Masivo de Datos Ambientales

**Orquestación de Pipeline ETL y Entorno Virtualizado**

**Presenta:** Sergio Steven Martinez Martinez

**Asesor Externo:** Dr. José Luis González Compean

**Institución:** TecNM Campus Ciudad Valles / Cinvestav Unidad  
Tamaulipas





# Introducción y Contexto

La gestión de datos ambientales en México enfrenta el reto de la dispersión y la heterogeneidad de formatos (CSV, Excel, Shapefiles antiguos).

Se requiere integrar información de dependencias clave: CONAGUA, SEMARNAT, INEGI, CONABIO, ASEA, PROFEPA, entre otras.

La solución exige centralizar, limpiar y estandarizar estos datos para facilitar su posterior análisis geoespacial y estadístico.

# Objetivo General

**1**

**Desarrollar e implementar un protocolo de gestión de datos geoespaciales y estadísticos.**

**2**

**Construir un pipeline ETL automatizado para la integración de la información.**

**3**

**Desplegar un repositorio centralizado y virtualizado de alta disponibilidad.**

# Arquitectura Tecnológica (El Stack)



## Orquestación y Lógica

Python



## Procesamiento y Transformación

Pandas, GeoPandas, PyMongo



## Infraestructura y Virtualización

Docker y Docker Compose



## Almacenamiento

MongoDB (Base de datos NoSQL óptima para manejar propiedades tabulares y geometrías espaciales en JSON).

# Metodología del Pipeline ETL

1

## Extracción (Extract)

Lectura programada de formatos diversos (.csv, .xlsx, .xls, .shp) con manejo de diferentes codificaciones (latin-1).

2

## Transformación (Transform)

Limpieza de valores nulos, homologación de tipos de datos (strings y floats), reestructuración de encabezados desfasados y extracción de polígonos a formato GeoJSON.

3

## Carga (Load)

Inserción masiva y automatizada de diccionarios en el contenedor de base de datos.





# Despliegue y Solución de Retos

## Infraestructura Contenerizada

Levantamiento de la infraestructura mediante contenedores aislados, garantizando la persistencia a través de volúmenes locales.

## Procesamiento por Lotes

Procesamiento optimizado por lotes (chunks de 10,000) para evitar desbordamientos de memoria en archivos masivos.

## Validación en Tiempo Real

Validación de datos en tiempo real para descartar registros vacíos y forzar compatibilidad de llaves en MongoDB.

# Resultados Obtenidos

11

## Colecciones temáticas

asea\_residuos, inegi\_usosuelo, conabio\_especies, etc.)  
operativas al 100%.

1,400+

## Polígonos espaciales

Integración de decenas de miles de registros tabulares y más  
de 1,400 polígonos espaciales listos para su explotación.

Consolidación exitosa de la base de datos "Residencia" en el puerto local 27017.



# Conclusión



## **Unificación de información fragmentada**

Se logró unificar información fragmentada gubernamental en un ecosistema centralizado.



## **Infraestructura escalable y automatizada**

La infraestructura desarrollada es escalable, replicable y totalmente automatizada.



## **Base técnica sólida**

Se estableció una base técnica sólida, cumpliendo el requerimiento estructural para iniciar la fase analítica del proyecto.

